



Análise e Previsão de Séries Temporais com Inteligência Artificial

Análise e Previsão de Séries Temporais com Inteligência Artificial

Arquitetura Convolutional Neural Network (CNN)

Convolutional Neural Networks (CNNs) são uma classe de redes neurais profundas projetadas para lidar com dados estruturados em grade, como imagens, que são inerentemente multidimensionais. Propostas por Yann LeCun, as CNNs são inspiradas no córtex visual do cérebro e têm sido amplamente aplicadas em várias tarefas de visão computacional, como reconhecimento de imagens, detecção de objetos, segmentação semântica e geração de imagens. Acesse e leia o material complementar abaixo:

<https://www.deeplearningbook.com.br/introducao-as-redes-neurais-convolucionais/>

A arquitetura de uma CNN é composta de uma série de camadas alternadas que realizam convoluções e pooling, seguidas por uma ou mais camadas totalmente conectadas (dense layers). As principais camadas em uma CNN são:

Camadas convolucionais: As camadas convolucionais são a base das CNNs. Elas aplicam filtros (também chamados de kernels) a pequenas regiões da imagem de entrada para aprender características locais. A convolução desliza os filtros sobre a imagem, calculando o produto escalar entre os pesos do filtro e os pixels da imagem, gerando um mapa de características (feature map). A quantidade de filtros aplicados determina o número de mapas de características na camada convolucional. A convolução preserva a estrutura espacial dos dados e permite que a rede aprenda padrões locais e hierárquicos.

Funções de ativação: Após a convolução, uma função de ativação é aplicada aos mapas de características. A função de ativação introduz não-linearidade na rede, permitindo que ela aprenda representações mais complexas. A função de ativação mais comum em CNNs é a ReLU (Rectified Linear Unit), que tem a propriedade de ser computacionalmente eficiente e ajudar a mitigar o problema do desaparecimento do gradiente.

Camadas de pooling: As camadas de pooling (também conhecidas como subsampling) são usadas para reduzir a dimensionalidade espacial dos mapas de características, tornando a rede mais eficiente em termos computacionais e de memória, e ajudando a torná-la invariante a pequenas mudanças na posição dos objetos na imagem. O pooling mais comum é o max-pooling, que seleciona o valor máximo em uma janela deslizante aplicada ao mapa de características.

Camadas totalmente conectadas: Após várias camadas convolucionais e de pooling, uma ou mais camadas totalmente conectadas (dense layers) são usadas para classificação ou regressão. A última camada totalmente conectada geralmente usa uma função de ativação softmax para classificação ou uma função de ativação linear para regressão.

Camada de dropout (opcional): A camada de dropout é uma técnica de regularização que pode ser aplicada entre camadas totalmente conectadas para reduzir o risco de sobreajuste (overfitting). Durante o treinamento, a camada de dropout "desliga" aleatoriamente um percentual de neurônios, forçando a rede a aprender representações mais robustas e menos dependentes de neurônios individuais.



As CNNs são treinadas usando retropropagação (backpropagation) e otimização por gradient descent, assim como outras redes neurais. A arquitetura das CNNs é amplamente usada em visão computacional, mas também pode ser usada com séries temporais como veremos nas aulas a seguir.